

**AMERICAN INTERNATIONAL
UNIVERSITY-BANGLADESH**
Faculty of Science and Technology



Project Report

Assignment Title:	Final Project Report		
Assignment No:	01	Date of Submission:	30 May 2025
Course Title:	Introduction to Data Science		
Course Code:	CSC4180	Section:	G
Semester:	Spring	2024-25	Course Teacher: Dr. Ashraf Uddin

Declaration and Statement of Authorship:

1. I/we hold a copy of this Assignment/Case-Study, which can be produced if the original is lost/damaged.
2. This Assignment/Case-Study is my/our original work and no part of it has been copied from any other student's work or from any other source except where due acknowledgement is made.
3. No part of this Assignment/Case-Study has been written for me/us by any other person except where such collaboration has been authorized by the concerned teacher and is clearly acknowledged in the assignment.
4. I/we have not previously submitted or currently submitting this work for any other course/unit.
5. This work may be reproduced, communicated, compared and archived for the purpose of detecting plagiarism.
6. I/we give permission for a copy of my/our marked work to be retained by the faculty for review and comparison, including review by external examiners.
7. I/we understand that Plagiarism is the presentation of the work, idea or creation of another person as though it is your own. It is a form of cheating and is a very serious academic offence that may lead to expulsion from the University. Plagiarized material can be drawn from, and presented in, written, graphic and visual form, including electronic data, and oral presentations. Plagiarism occurs when the origin of their arterial used is not appropriately cited.
8. I/we also understand that enabling plagiarism is the act of assisting or allowing another person to plagiarize or to copy my/our work.

* Student(s) must complete all details except the faculty use part.

** Please submit all assignments to your course teacher or the office of the concerned teacher.

Group Name/No.: 02

No	Name	ID	Program	Signature
1	MD. TAMJID HOSSAIN	22-46460-1	BSc [CSE]	
2	WASIF ASAD ALVI	22-46451-1	BSc [CSE]	
3	RIFAT TALUKDAR	22-46428-1	BSc [CSE]	
4	MD. TANZIUL HAQUE	22-46435-1	BSc [CSE]	
5			Choose an item.	
6			Choose an item.	
7			Choose an item.	
8			Choose an item.	
9			Choose an item.	
10			Choose an item.	

Faculty use only

FACULTY COMMENTS

Marks Obtained

Total Marks

Table of Contents

Topics	Page Number
Objective	2
Project Task – Web Scrapping	2
Project Task – Text Processing	4
Project Task – Exploratory Text Analysis	5
Project Task – Topic Modeling	7
Conclusion	13

Project Report

1. Objective

The objective of this project was to perform a complete text analysis on Bangla news articles scraped from an online news portal. It will help to develop practical skills in web scraping, text preprocessing, visual analytics, and topic modeling using real-world news articles. In the whole project we have done the below steps:

- We have scrapped Bangla news article texts from multiple pages linked in the home page of NTV BD news portal (<https://www.ntvbd.com/>).
- Then we performed preprocessing steps on the scrapped article texts. For example, we've performed punctuation removal, number or digit removal, unnecessary space removal, and some basic Bangla stopwords removal.
- Then we've done word frequency analysis and visualization using wordcloud
- After that, we've performed topic modeling using Latent Dirichlet Allocation (LDA) and visualized each topic's top words using bar plots.
- Lastly, we've visualized and interpreted discovered topics using Document-topic distribution and stacked bar plots.

2. Project Tasks

A. Web Scrapping

We've selected Bengali news portal NTV BD to scrape all the article texts linked in the homepage of the site. The link to the news portal is: (<https://www.ntvbd.com/>). Using the rvest library in R, we collected URLs and extracted article content from the <p> tags in individual article pages. The steps we followed are given below:

- First, we loaded the homepage HTML using the rvest package (read_html()).
- We extracted the links from headline tags (h2 a, h3 a, h4 a) using html_nodes().

- The links and titles were stored in a data frame, cleaning incomplete URLs by prepending the base URL when necessary.
- We filtered out invalid or empty links, removed duplicates, and saved these URLs along with their titles to a CSV file (ntv_links_with_labels.csv) encoded in UTF-8 to preserve Bangla characters.
- Next, we read the first 60 article links back from the CSV to limit the scraping load.
- For each article URL, a custom function extract_article_details() was used:
 - It loaded the article page HTML.
 - Removed unwanted nodes (e.g., inactive tab panels).
 - Extracted all paragraph (<p>) tag texts, concatenated them, and returned as the article content.
 - Errors were handled gracefully to avoid script interruption.
- All scraped article texts along with their URLs were saved in a CSV file (ntv_article_texts.csv) again with UTF-8 encoding.

This procedure ensures structured data collection from multiple article pages linked on the homepage, ready for text analysis.

Here is a code snippet example:

```
paragraphs <- page %>%
  html_nodes("p") %>%
  html_text() %>%
  paste(collapse = " ")
```

Files generated:

- ntv_links_with_labels.csv – 60 URLs and titles
- ntv_article_texts.csv – Full scraped article texts

Here is some of the examples of the article texts from our generated csv files:

1	full_url	article_text
3	https://www.ntvbd.com/bangladesh/news-1564189	বিশ্বজুড়ে ক্রমবর্ধনুণ্ডি আস্থারতার আবহে এশিয়ার দেশগুলোর মধ্যে প্রাপ্তির অন ইন্ডিয়া মডেলস-ই-ইন্ডিয়াল মসালীমিন (এআইএমআইএম)-এর প্রধান ও ১৯৮৮ সাল থেকে বিশ্বজুড়ে সংগঠিত পূর্ণ অঞ্চল বাংলাদেশ শাস্ত্ররক্ষার অভ্যন্তর প্রাপ্ত প্রশাসন টিম শিক্ষার্থীদের জন্য আগ্রাসীভাবে ভিসা বাতিল করবে বলে। মার্কিন ফেসিডেন্ট ডেনার্স ট্রাম্পের আরোপিত ব্যাপক শুল্কের আদেশ বাতিল অ্যামেরিকান ইন্টারন্যাশনাল জানিয়েছে গত দুই বছরে নাইজেরিয়ার মধ্য ও উচ্চ বাংলাদেশে আনুষ্ঠানিকভাবে চালু হতে যাচ্ছে গুগলের ডিজিটাল প্রেমেন্ট সেবা বাংলাদেশ জুয়েলস আসোসিয়েশনের (বাজুন) সহ-সভাপতি মো. রিপেনুল হাস বাংলাদেশের অন্তর্বর্তী সরকারের প্রধান উপদেষ্টা অধ্যাপক মুহাম্মদ ইউনুস বকে মার্কিন সরকারের একটি বিশেষ পদ থেকে পদত্যাগ করবেন ধনকুরের ইলন মাদ্য নিয়ন্ত্রণ কাউন্সিলের প্রধান ইয়েহেই সাসাকাওয়া গতকাল বৃথাবার (২৮ মে) অন্তর্বর্তী সরকারের প্রধান উপদেষ্টা অধ্যাপক ড. মুহাম্মদ ইউনুস বলেছেন, 'মান দেশের ৬ অঞ্চলে বৃষ্টি অথবা বজ্রবৃষ্টিসহ অস্থায়ীভাবে ঝড়ে হাওয়া বয়ে যেতে' সকাল থেকে টানা বৃষ্টিতে ঢাকার বায়ুমানের উন্মত্ত হয়েছে। আজ বৃহস্পতিবার (বঙ্গোপসাগরে সৃষ্টি লম্বুচাপের কারণে চাঁদপুরে ভারী বৃষ্টিপাত ও ঝড়ে হাওয়া ব ইসরাইলের প্রধানমন্ত্রী বেনিয়ামিন নেতান্যাহু বৃথাবার (২৮ মে) এক ঘোষণা জ চলতি বছরের ডিসেম্বরের মধ্যে জাতীয় সংসদ নির্বাচন আয়োজনের জন্য অন্তর্বর্তী ইসরাইলের প্রধানমন্ত্রী বেনিয়ামিন নেতান্যাহুকে ইরানে সামরিক হামলা চালা ব্যর্থতার বৃত্ত থেকে বের হতে পারল না বাংলাদেশ। বদলেনি ভাগ। পাকিস্তানের হামজা চৌধুরীর পর সবচেয়ে বৈশ উন্মাদনা শর্মিত সোমকে ধিরে। কানাডা নয় রাজনীতির মাঠে নির্বাক্ষয় হলেও ভালোবাসায় অটোন প্রয়াখালোর কৃষক সোহাগ বালিউডের পর্যাচিত মুখ অভিনেত্রী দীপিকা কক্ষর। তিনি মরণব্যাধি ক্যানসার দে কানসার টিশুরাপ্পী এক চারণরাপ্তি। সাম্প্রতিক রচনাত্মক ক্ষেত্রে ক্যানসার
24	https://www.ntvbd.com/health/news-1562612	

Figure 1: Article text example from CSV

B. Text Processing

After scrapping the article texts from each of the news links in the homepage, we've performed basic text processing for each of the articles. Since there's a complexity of processing Bangla text processing we've had to use the Stringr library to process the texts. We've also used tm, and tokenizers libraries. For example,

```
cleaned_articles <- article_text %>%
  str_replace_all("[[:punct:]]", " ") %>%
  str_replace_all("[[:digit:]]", " ") %>%
  str_replace_all("\b[a-zA-Z]+\b", " ") %>%
  str_replace_all("\s+", " ") %>%
  str_remove_all(paste0("\b(", paste(bangla_stopwords, collapse =
" | "), ") \b"))
```

From the code snippet, it can be seen that we've performed steps like:

- Punctuation, digits, newlines, and tabs removal
- English words removal (using regex: \b[a-zA-Z]+\b)
- Custom Bangla stopwords removal
- Normalized whitespaces

After performing the preprocessing steps the article texts looks like this:

```
> print(substr(cleaned_articles, 1, 500))
```

[1] "বিশ্বজুড়ে ক্রমবর্ধিত অভিযান আবাহন এশিয়ার দেশগুলোর প্রাপ্তিরিক নির্ভরতাকে সংঘাতের বদলে সহযোগিতার নতুন দিগন্তে রূপান্তরের আয়ন জানিয়েছেন বাংলাদেশ সরকারের প্রধান উপদেষ্টা।
দেষ্টা অধ্যাপক মুহাম্মদ ইউসুফ আজ বৃহস্পতিবার মে টাকিওর ইস্পারিয়াল রেটেলের ফাঁজ করে অনুষ্ঠিত নির্মলা কোর্টের তত্ত্ব ফিল্ডের অব এশিয়া সমন্বয়ে অশাস্ত্র বিষে এশিয়ার চ্যালেঞ্জ শীর্ষক
মূল বক্তব্য উপস্থুত করে তিনাটি শুনা দারিদ্র্য বেকারত্ব নেট কর্ম নির্গমন সাহচরী দৃষ্টিভঙ্গ তুলে ধরে এশিয়ার নতুন ভবিষ্যৎ নিয়মের আ"

[2] "আন ইন্ডো মার্কিন ইউনিয়ন এবং ইউরোপ প্রধান যাবদীরাবাদ নিবাচিত সংসদ সদস্য আসাদুল্লাহ ওয়াহেদ পাকিস্তানের ইসলামিক প্রচারণার বিকল্পে কড়া অবস্থান নিয়েছেন বলেছেন তারেতে কোটি সার্বিত মুসলিমদের প্রাক্তিকানে বিকল্প কথা বলার সময় আসাদুল্লাহ এবং পাকিস্তান বিশ্বজুড়ে বিশেষ আবব মুসলিম বিশ্বের কাছে ভুল বার্তা ছড়াচ"

[3] "সাল বিশ্বজুড়ে সংঘাতপূর্ণ অঞ্চলে বাংলাদেশ শাস্তিরসূর্য আত্মস্তুত গুরুত্বপূর্ণ ভূমিকা পালন আসছেন উর্দেখ ভূমিকার প্রশংসন ইউনেস্কো ইইচ জাতিসংঘ শাস্তিরসূর্য সিবসু উপর

Tokenization:

- We also used tokenize_words() from the tokenizers package to split text into individual words/tokens.

[[18]]								
[1]	"ইসরায়েলের"	"প্রধানমন্ত্রী"	"বেনিয়ামিন"	"মেতানিয়াছকে"	"ইরানে"	"সামরিক"	"হামলা"	"চলানো"
[9]	"বিরত"	"থাকুর"	"স্তর্ক"	"করেছেন"	"মার্কিন"	"প্রেসিডেন্ট"	"ডোক্টর"	"ট্রাম্প"
[17]	"পরমাণু"	"চুক্তি"	"নিয়ে"	"ওয়াশিংটন"	"তেহরানের"	"চলমান"	"আলোচনার"	"ধরনের"
[25]	"পদক্ষেপ"	"অনুপ্যুক্ত"	"বলে"	"উল্লেখ"	"করেছেন"	"ট্রাম্প"	"ধর্ব"	"এ্যেলিপি"
[33]	"স্থানীয়"	"সময়"	"আজ"	"বৃথাবাদ"	"মে"	"সাবাদিকদের"	"আলাপকালে"	"ট্রাম্প"
[41]	"নিষ্ঠিত"	"গত"	"স্বাক্ষরে"	"নেতানিয়াহুর"	"কেনালপে"	"ইসরায়েলি"	"প্রধানমন্ত্রীকে"	"এমন"
[49]	"কোনো"	"পদক্ষেপ"	"নিতে"	"বলেছেন"	"যা"	"আলোচনায়"	"ব্যাপ্তি"	"বাটাতে"
[57]	"পরে"	"ট্রাম্প"	"আমি"	"শুরু"	"বলেছি"	"এটি"	"এখন"	"উচ্চতা"
[65]	"নয়"	"আমরা"	"খুব"	"ভলে"	"আলোচনা"	"করছি"	"আমরা"	"সমাধানের"
[73]	"খুব"	"কাছকাছি"	"আমি"	"মনে"	"কারি"	"তারা"	"ইরান"	"চুক্তি"
[81]	"করতে"	"চায়"	"যদি"	"আমরা"	"চুক্তি"	"করতে"	"পারি"	"তাহলে"
[89]	"জীৱন"	"বাচ্চনো"	"যাবে"	"সালে"	"ট্রাম্পের"	"প্রথম"	"মেয়াদে"	"পরমাণু"
[97]	"চুক্তি"	"সবে"	"অসে"	"সুন্দরী"	"সংপ্রতি"	"তেহরান"	"ওয়াশিংটন"	"পরমাণু"
[105]	"চুক্তি"	"নিয়ে"	"সফর্স"	"আলেচনা"	"যা"	"চুক্তি"	"বাস্কর"	"সুরোচি"
[113]	"পৰ্যায়ের"	"যোগাযোগ"	"আগে"	"ইরান"	"ইস্তত"	"দণ্ডিল"	"যুক্তিগৃহীত"	"চুক্তি"
[121]	"হুলে"	"তারা"	"জাতিসংঘের"	"পরমাণু"	"প্রথবেক্ষকদের"	"স্থুপনা"	"প্রারম্ভনের"	"অনুমতি"
[129]	"দিতে"	"গোর"	"ইসরায়েলে"	"তার"	"চিরাঙ্গের"	"ইসরানের"	"বিকল্পে"	"বারবার"
[137]	"সামরিক"	"পদক্ষেপের"	"ইমারি"	"আসছে"	"গত"	"স্তুতিরে"	"মার্কিন"	"গণমাধ্যমের"
[145]	"ধৰবের"	"কো"	"হয়েছিল"	"যুক্তরাষ্ট্র"	"ইরান"	"আলোচনার"	"মধ্যেও"	"ইসরায়েল"
[153]	"ইরানের"	"পরমাণু"	"স্থাপনাগুলোতে"	"হামা"	"চালনের"	"প্রস্তুতি"	"নিয়ে"	"ট্রাম্প"
[161]	"অবশ্য"	"সামরিক"	"পদক্ষেপের"	"স্বাক্ষরণ"	"দিতে"	"উভয়ের"	"দেশনি"	"বলেছেন"
[169]	"প্রথমে"	"চুক্তি"	"যাবে	"সময়"	"চান"	"ডোক্টর"	"কোনো"	
[177]	"হামলা"	"হুলে"	"সেটি"	"নেতৃত্ব"	"দেবে"	"ইসরায়েল"	"যুক্তরাষ্ট্র"	"নয়"
[185]	"পশ্চিমা"	"শুক্তিগুলো"	"দীর্ঘদিন"	"ধৰে"	"ইরানকে"	"প্রমাণবিক"	"অন্তর্ব"	"তৈরির"
[193]	"চেষ্টার"	"অভিযোগ"	"অসহে"	"ধাৰাবাহিকভাবে"	"এসব"	"অভিযোগ"	"আঁকাকাৰ"	"প্রামাণবিক"
[201]	"কর্মসূচিকে"	"সম্পূর্ণরূপে"	"শাস্তির্কূণ"	"বেসামুরক"	"উদ্দেশ্যে"	"পরিচালিত"	"বলে"	"দাবি"
[209]	"তেহরান"							

Figure 2: Sample tokenization

C. Exploratory Text Analysis

Corpus and Document-Term Matrix:

- Created a corpus object using the tm package from cleaned articles.
- Generated a Document-Term Matrix (DTM) to quantify word occurrences across documents.
- Filtered documents without any terms.

Frequency Analysis:

- Calculated total frequency of each word and sorted them.

Example Code Snippet:

```
# DTM matrix and word frequency
m <- as.matrix(dtm)
row_totals <- rowSums(m)
dtm_filtered <- dtm[row_totals > 0, ]
m_filtered <- as.matrix(dtm_filtered)
word_freqs <- sort(colSums(m_filtered), decreasing = TRUE)
df <- data.frame(word = names(word_freqs), freq = word_freqs)
head(df)
```

Top 5 words with their frequency:

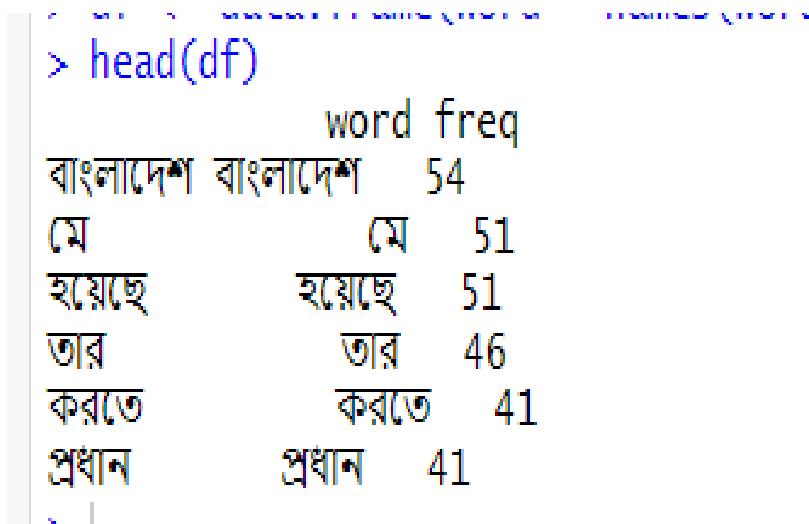


Figure 3: Top 5 most frequent words with their frequency

Visualization:

- We created word clouds and bar plots of the top frequent words using wordcloud and barplot.



Figure 4: Word cloud visualization

From the wordcloud, we can see that the word “বাংলাদেশ” has the highest frequency so it is bigger on the wordcloud as well. Similarly words with higher frequency has bigger sizes and lower frequency has smaller sizes.

Barplot of top 20 most frequent words from the articles:

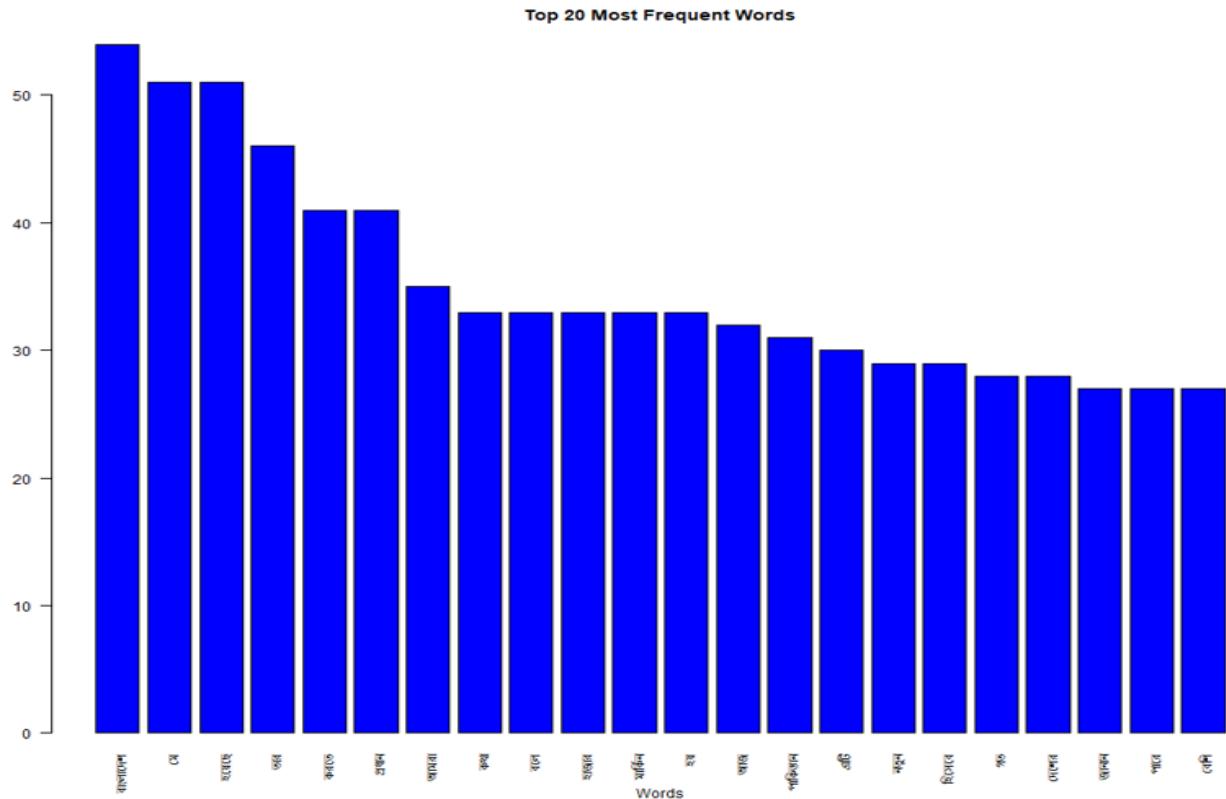


Figure 5: Top 20 most frequent words barplot

From the barplot, it can also be seen that the words “বাংলাদেশ”, “মে”, “হয়েছে”, “তার” etc have the highest frequencies.

D. Topic Modeling

For topic modeling we used tm, topicmodels, ggplot2 libraries. Then we followed the below steps for topic modeling:

- Applied Latent Dirichlet Allocation (LDA) with 5 topics using the topicmodels package.
- Extracted top terms per topic and plotted the top words for each topic.
- Visualized document-topic distributions to understand how topics are spread across articles.

Top terms per topic:

Below is a code snippet example for the top terms per topics:

```
# Topic Modeling with LDA
num_topics <- 5
lda_model <- LDA(dtm_filtered, k = num_topics, control = list(seed = 58))

# Top terms per topic
top_terms <- terms(lda_model, 10)
print(top_terms)
```

The result is:

```
> print(top_terms)
      Topic 1    Topic 2    Topic 3    Topic 4    Topic 5
[1,] "বাংলাদেশ" "প্রধান"   "পয়সা"    "মোহাম্মদ" "মার্কিন"
[2,] "তার"       "বাংলাদেশ" "সিরিজ"   "হামলার"  "ট্রাম্প"
[3,] "স্বকের"   "বলে"     "পাকিস্তান" "টিকিট"   "প্রশাসন"
[4,] "নতুন"     "উপদেষ্টা" "কোম্পানিটির" "বেশি"    "ক্ষমতা"
[5,] "করতে"    "করতে"   "সমাপ্ত"   "হয়"      "পদক্ষেপ"
[6,] "গ্রাহিয়ার" "আমরা"   "এটি"      "সিনওয়ার" "শুল্ক"
[7,] "বছর"      "সরকারের" "হয়েছে"   "মে"       "দেশের"
[8,] "হিসেবে"   "বাংলাদেশের" "বছরে"   "দেওয়া"   "পারে"
[9,] "জাতীয়"    "বিএনপির" "শেয়ারপ্রতি" "কথা"    "বড়"
[10,] "জানান"   "রহমান"   "বাংলাদেশ" "তার"    "হাজার"
```

Figure 6: Top 10 terms per topic

We can easily see the top terms of each of topics here. By seeing the terms we can assume what is the topic that was meant for those words. For example,

- Topic 1 can be assumed for National & Domestic Affairs
- Topic 2 can be assumed for Politics and Governance
- Topic 3 can be assumed for Finance & Economy
- Topic 4 can be assumed for Conflict, or Social Issues
- Topic 5 can be assumed for International Affairs.

Barplots for top words per topic:

Topic 1:

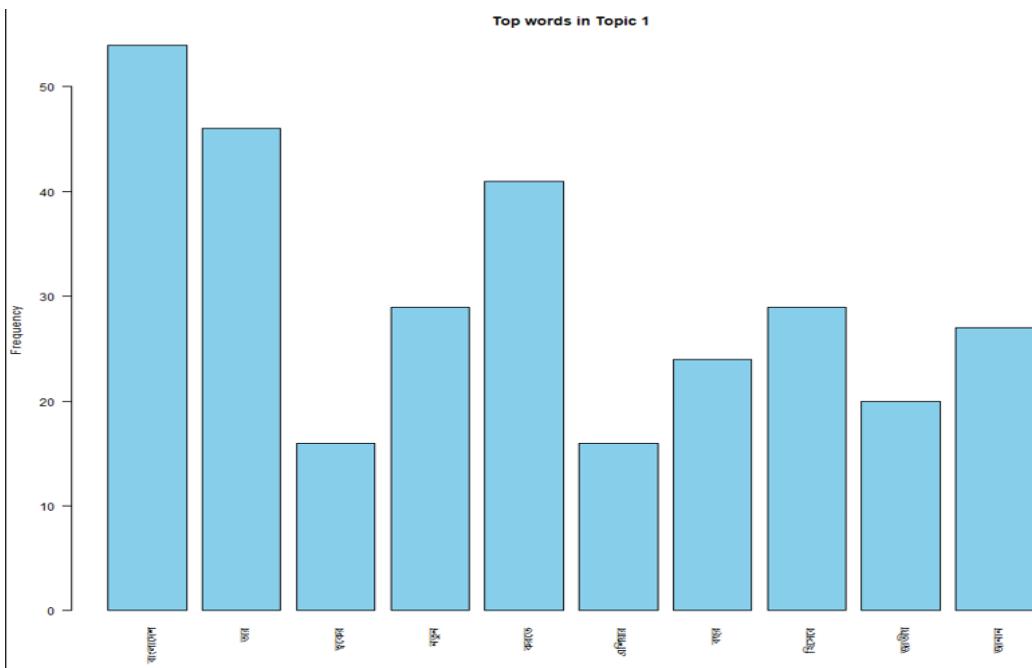


Figure 7: Top words for Topic 1

Topic 2:

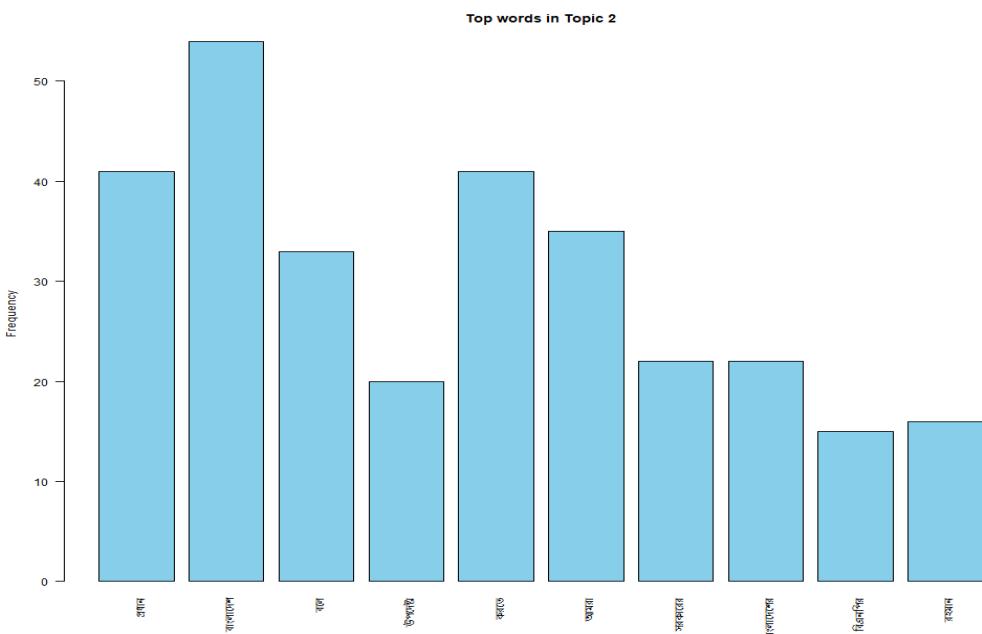


Figure 8: Top words for Topic 2

Topic 3:

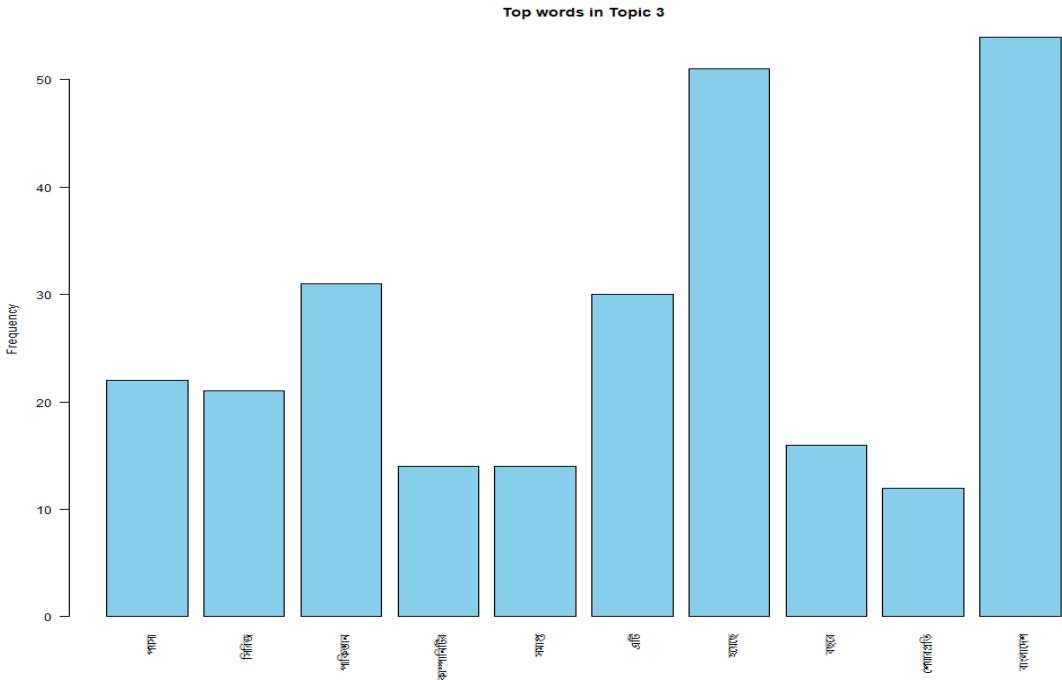


Figure 9: Top words for Topic 3

Topic 4:

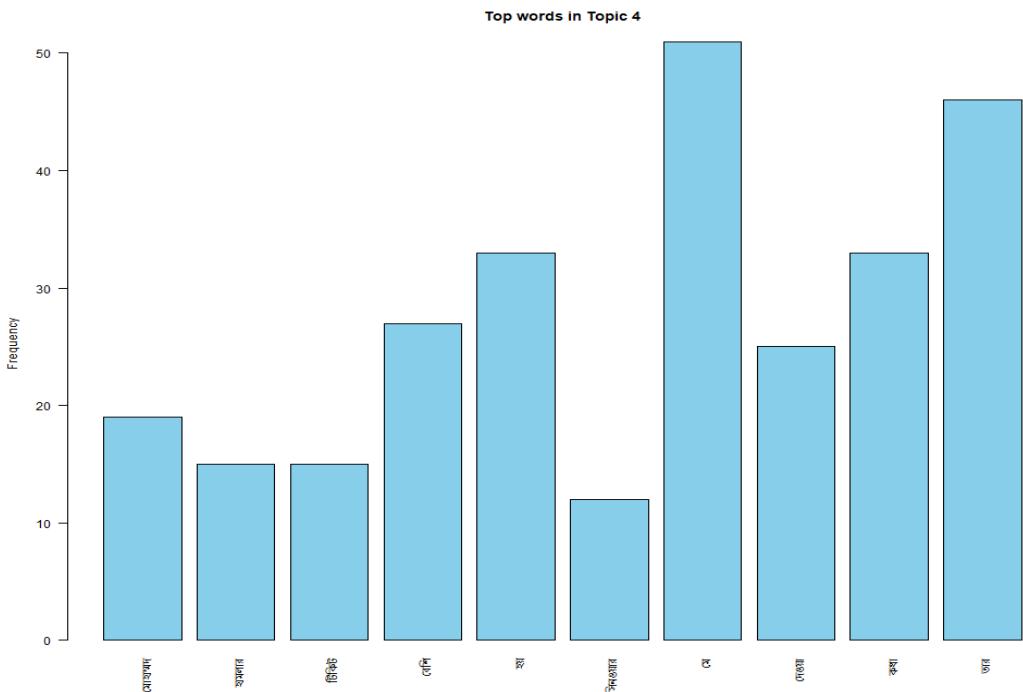


Figure 10: Top words for Topic 4

Topic 5:

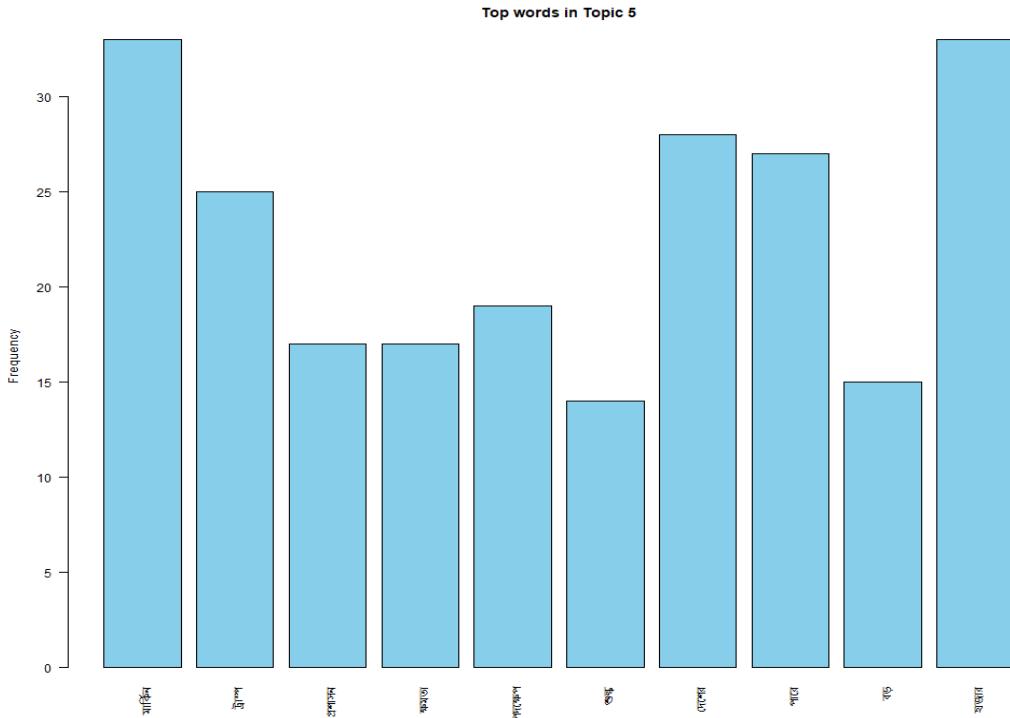


Figure 11: Top words for Topic 5

From the barplots, we can easily see and understand the top words of respective topics and their frequencies.

Document-topic distribution using Stacked Bar:

We visualized a document-topic distribution using a stacked bar. A document-topic distribution shows how much each topic contributes to each document in a corpus.

Example code snippet:

```
# Document-topic probabilities using tidytext
doc_topics <- tidy(lda_model, matrix = "gamma")

# View a sample
head(doc_topics)

# Sort Documents and Label Topic
doc_topics <- doc_topics %>%
  mutate(document = factor(as.integer(document)), levels =
sort(unique(as.integer(document))), topic = paste("Topic", topic))

# Plot Stacked bar chart
png("Document-Topic Distribution.png", width = 1000, height = 800)
```

```

ggplot(doc_topics, aes(x = factor(document), y = gamma, fill =
topic)) +
  geom_bar(stat = "identity") +
  labs(
    title = "Document-Topic Distribution",
    x = "Document",
    y = "Topic Probability",
    fill = "Topic"
  ) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 90))
dev.off()

```

Result of the document-topic distribution:

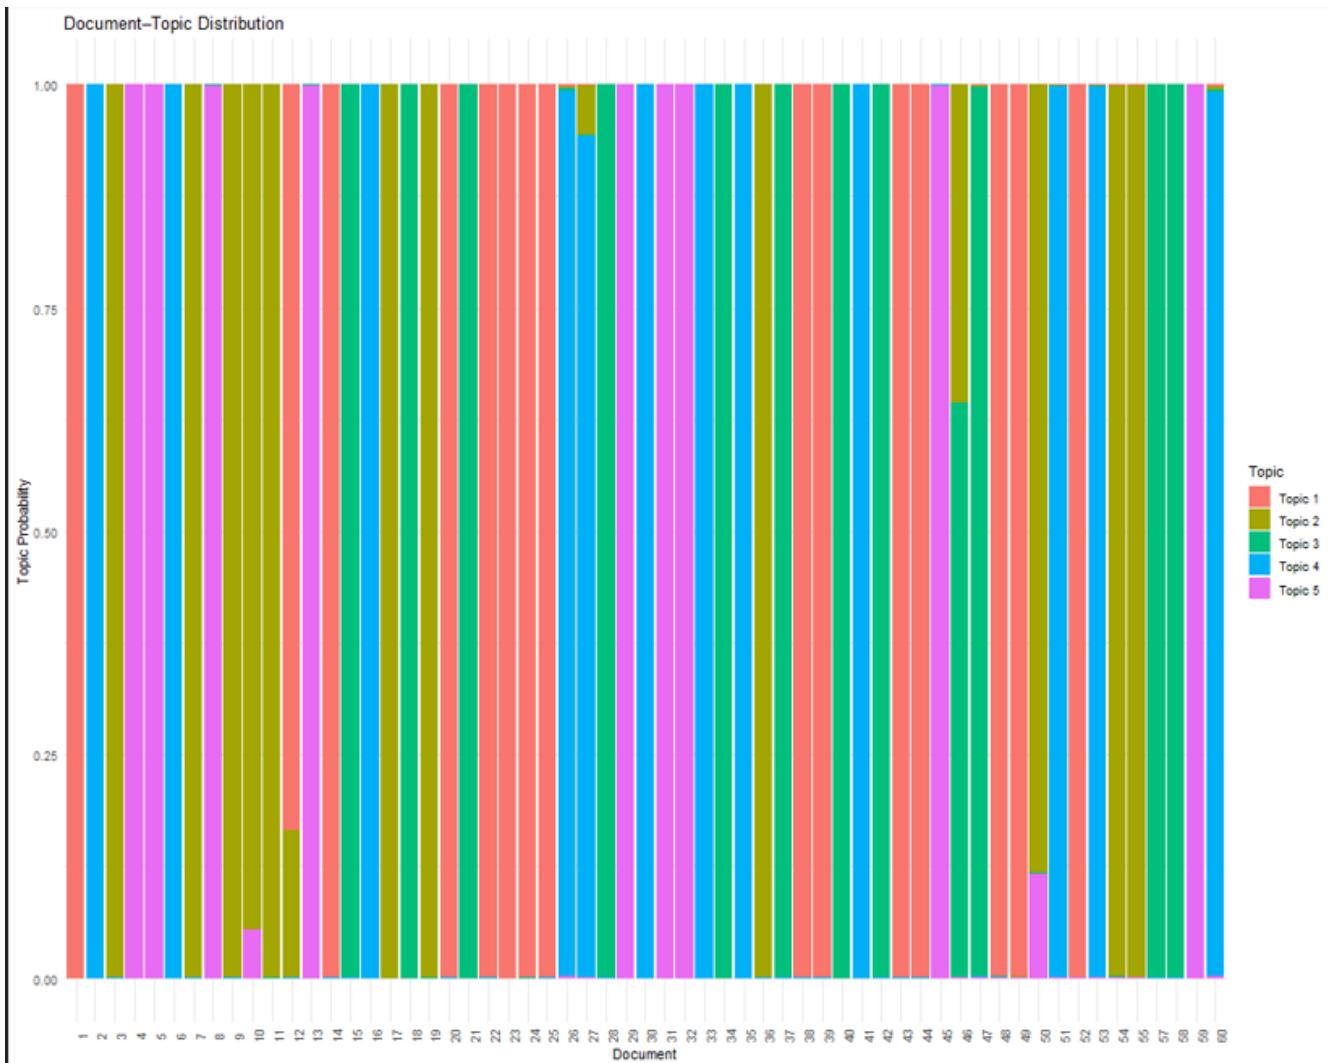


Figure 12: Document-topic distribution

From the image it can be seen that:

- Most documents are dominated by a single topic. This is shown by bars that are nearly entirely one color.
- A few documents have mixed topic distributions, where multiple colors appear in a single bar.
- For example, Document 10 and 47 show contributions from two or more topics, indicating a more diverse content.

Conclusion

This project was done for collecting and analyzing Bengali news articles from the NTV online news portal. Through web scraping, we gathered real-time data and applied text preprocessing techniques for Bengali language content. The use of topic modeling via Latent Dirichlet Allocation (LDA) allowed us to analyze news articles and their topics.

Overall, this project showcases the practical application of data science and NLP techniques in a real-world context involving the Bangla language. It highlights the importance of preprocessing and data visualization.